Optimisation des données de Bottleneck

Tony WENG

Analyses Exploratoires des Données

- 3 Datasets :
  - L’extraction de l’**ERP** (référence produit, prix et l’état du stock)
  - L’extraction de notre site **Web** (SKU, quantités vendues, description des produits, etc.)
  - Une table de **liaison** qui permet de lier les références entre la base de données du site Web et l’extraction de l’ERP de l’entreprise.

Analyses Exploratoires des Données

- Dataset **ERP**
- Caractéristiques :
  - **product_id** : identifiant du produit
  - **onsale_web** : indice binaire indiquant si le produit est en vente sur le web (*1*) ou non (*0*)
  - **price**, **purchase_price** : prix de vente et prix d'achat
  - **stock_quantity**, **stock_status** : quantité du stock et état du stock (*instock* ou *outofstock*)

Analyses Exploratoires des Données

- Dataset **ERP**
- Traitement réalisés
  - Nettoyages des données :
    - vérification de la cohérence entre stock_quantity et stock_status,
    - suppression des lignes affichant un prix ou un stock négatif
- Remarques éventuelles, pièges ou difficultés rencontrées
  - Avant de supprimer les lignes, il faut penser à vérifier si l'erreur peut être corriger d'abord.

Analyses Exploratoires des Données

- Dataset **WEB**
- Caractéristiques retenues (28 initialement) :
  - **sku** : identifiant sku du produit
  - **total_sales** : nombre de vente sur le mois d'octobre
  - **tax_status** : indique si le produit est soumis à des taxes ou non (*taxable*)
  - **product_type** : type du produit
  - **post_title** et **post_name** : deux variables décrivant le nom du produit

Analyses Exploratoires des Données

- Dataset **WEB**
- Traitement réalisés
  - Nettoyages des données :
    - suppression de 22 colonnes sur les 28 initiales,
    - suppression des lignes n'ayant pas d'identifiant sku,
    - nettoyage des lignes avec des identifiants sku en double, vérification sur tax_status
- Remarques éventuelles, pièges ou difficultés rencontrées
  - Cas particulier du bon cadeau de 25€ qu'il fallait traiter à part
  - Il fallait bien définir quelles colonnes conserver et ne garder que les colonnes pertinentes à l'analyse

Analyses Exploratoires des Données

- Dataset **LIAISON**
- Caractéristiques :
  - **id_web** : identifiant du produit sur le site Web
  - **product_id** : identifiant du produit sur l'ERP
- Traitement réalisés (aucun à ce stade)
- Remarques éventuelles, pièges ou difficultés rencontrées
  - Certaines cases sont vides dans le dataframe, cela s'explique par le fait que tous les produits ne sont pas en vente sur le site Web

Fusion ou consolidations des données

- Choix des attributs :
  - Déjà effectué lors du nettoyage des différents dataframes
- Clés utilisés :
  - On va d'abord joindre les dataframes **ERP** et **LIAISON** sur la clé **product_id** pour attribuer un **id_web** à chaque produit
  - On va ensuite y joindre le dataframe **WEB** en faisant correspondre **id_web** et l'identifiant **sku** afin de faire correspondre les informations du produit avec celles du site Web

Fusion ou consolidations des données

- Vigilances particulières au cours du traitements
  - Faire une jointure sur le dataframe **ERP** afin de s'assurer que tous les produits sont représentés, même ceux qui ne sont pas en vente sur le site Web
  - Bien vérifier le nombre de lignes des dataframes créés pour voir s'il en manque
  - Vérifier la cohérence des données maintenant qu'elles ont été fusionnées
- Difficultés ou pièges rencontrés
  - Lors de la première jointure, 3 lignes affichaient un indice **onsale_web** *1 (Vrai)*, mais aucun **id_web** ne correspondait, il fallait alors changer l'indice à *0 (Faux)*
  - Lors de la deuxième jointure, 20 lignes affichaient un **id_web** mais pas d'identifiant **sku**, cela veut dire que ces produits ne sont pas en vente sur le site Web, ou qu'ils ne le sont plus

Analyses univariées du prix

- Méthodes statistiques employées
  - Identification par le Z-score :
    - Le Z-score est le nombre d'écart-type d'écart entre la valeur étudiée et la moyenne
    - On obtient une moyenne de *32,36€* et un écart-type de *26,64€*
    - En observant les produits dont le z-score est supérieur à 3 *(prix supérieur à 112,28€)*, on trouve 17 produits dont le prix est bien au dessus de la moyenne, qu'on appellera des valeurs aberrantes

Analyses univariées du prix

- Méthodes statistiques employées
  - Identification par l'intervalle interquartile :
    - L'intervalle interquartile (IQR) est taille de la plage de valeurs dans laquelle se trouve la moitié centrale des valeurs (entre le premier quartile Q1 et le troisième quartile Q3)
    - Afin d'identifier des valeurs aberrantes, on définit deux seuils inférieur et supérieur qui valent respectivement **Q1 - 1.5 * IQR** *(-26.50€)* ou **Q3 + 1.5 * IQR** *(83.10€)*. Le seuil inférieur n'est pas pertinent dans notre cas
    - On observe 36 produits dont le prix est au dessus du seuil supérieur, soit 4,36% du catalogue

Analyses univariées du prix

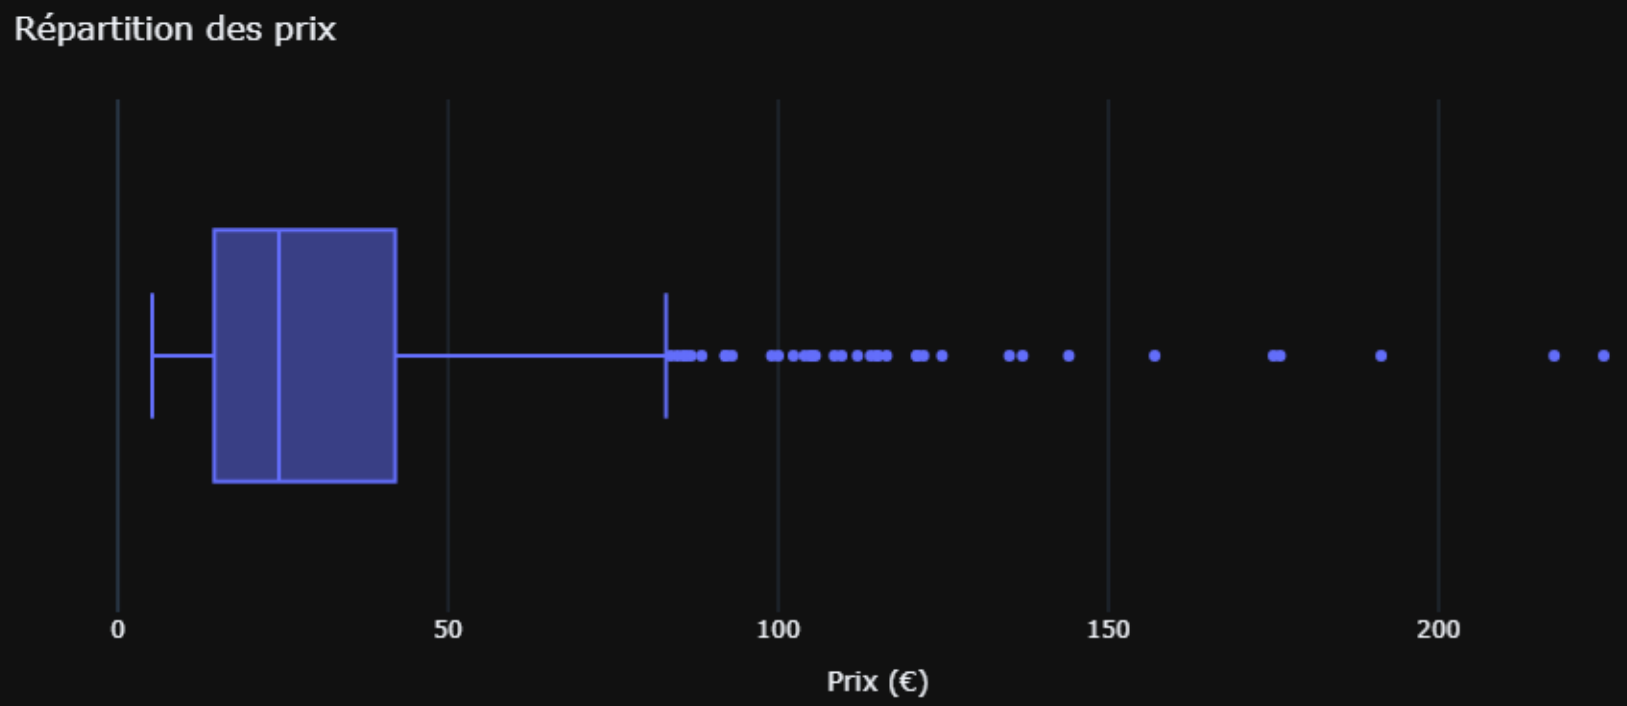

Analyses univariées du prix

- Limites éventuelles de l’analyse :
  - Méthode efficace pour identifier les valeurs aberrantes et les cas particuliers, mais implique un échantillon plus ou moins homogène
  - Dans notre cas, l’échantillon n’est pas homogène car certaines de nos bouteilles valent beaucoup plus cher que d’autres, ce qui mène à ces valeurs aberrantes
  - En effet, pendant les analyses effectuées, on a pu observer que les prix de vente étaient plus ou moins proportionnels au prix d’achat, que ce soit pour l’échantillon entier ou bien pour l’échantillon avec seulement les valeurs aberrantes

Analyses univariées du prix

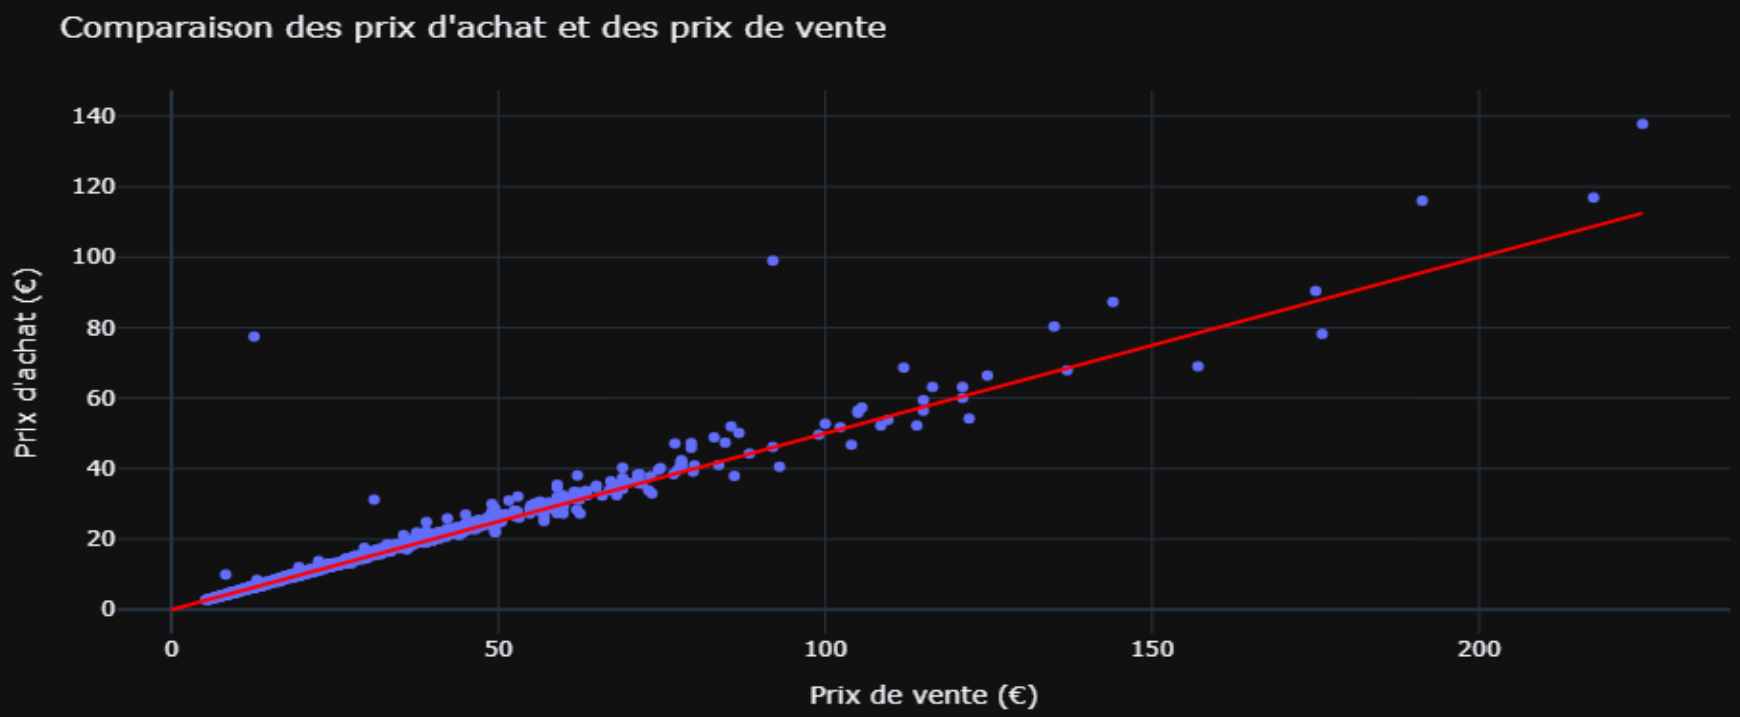

Analyses complémentaires : CA et quantité

- Méthode statistique employée
  - Le principe de Pareto :
    - Méthode permettant de montrer qu'une minorité de l'échantillon produit une majorité d'effets (dans notre cas, de vente)
    - On obtient un CA général de *143324.10€*
    - En suivant cette méthode, on observe que 80% du CA correspond à *433* articles soit *52,48%* du catalogue
    - 80% des ventes en quantité correspond également à *433* articles soit *52,48%* du catalogue

Analyses complémentaires : CA et quantité

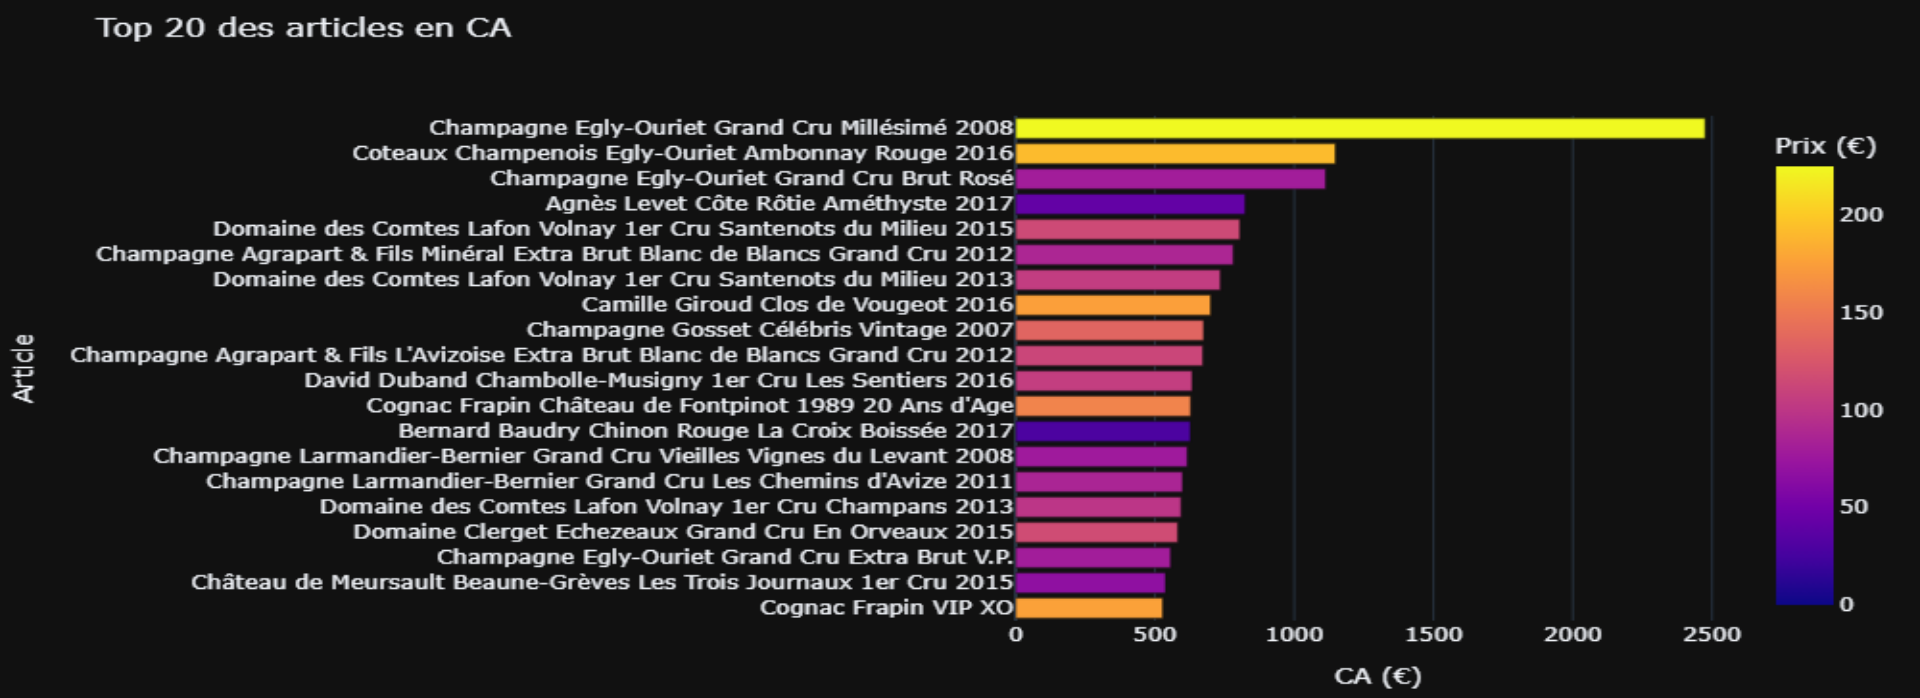

Analyses complémentaires : CA et quantité

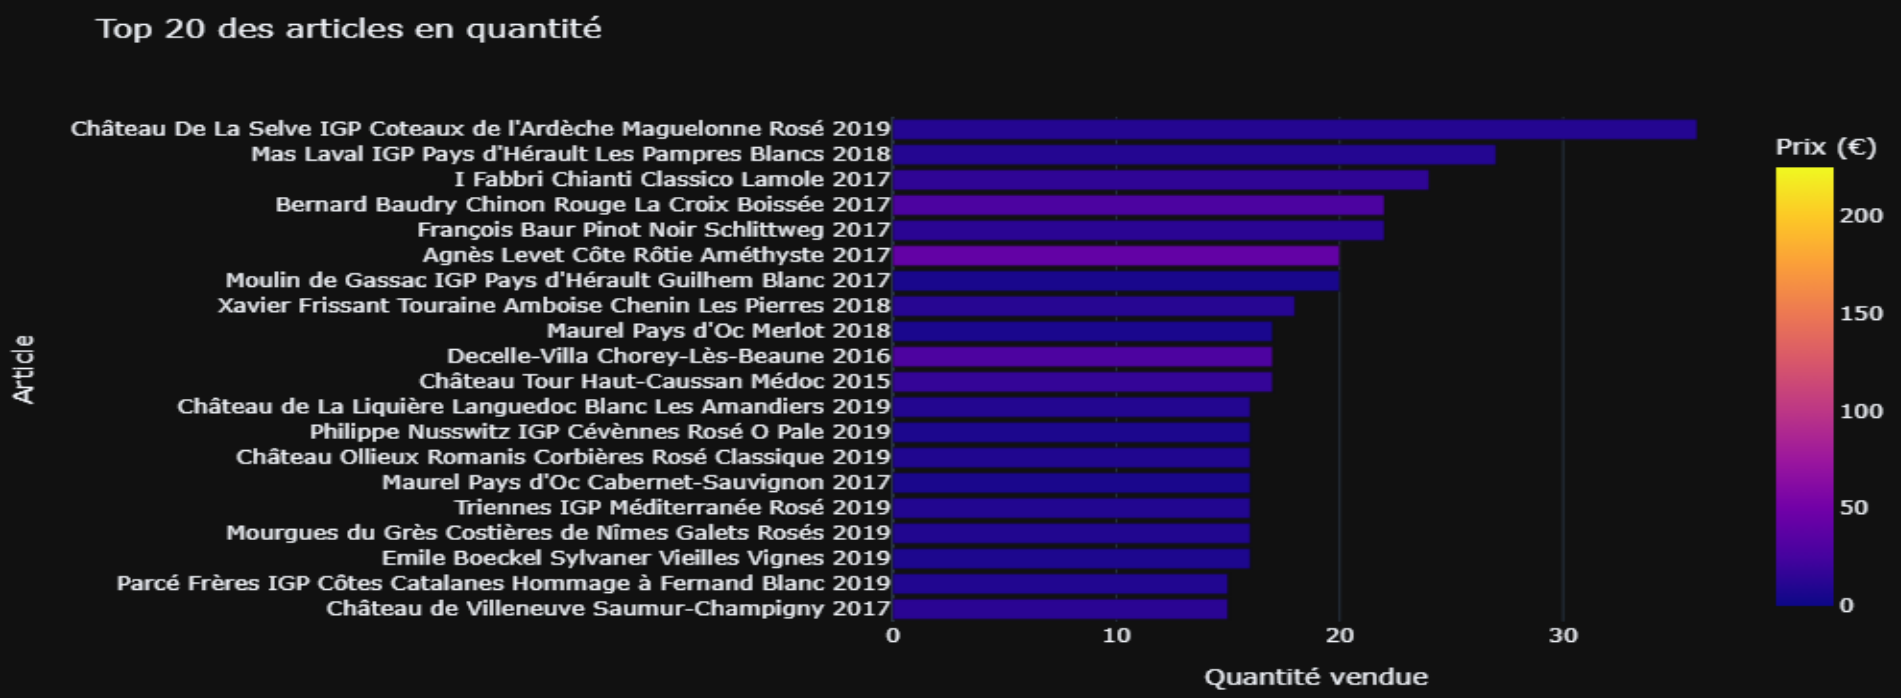

Analyses complémentaires : CA et quantité

- L’analyse sur le CA nous montre que ce sont les articles les plus chers qui génèrent le plus grand CA
- L’analyse sur la quantité nous montre que ce sont les articles les moins chers qui génèrent le plus grand nombre de ventes
- Les deux analyses nous montrent que seulement la moitié des articles génèrent 80% de la totalité du CA ou du nombre de ventes, respectivement

Analyses complémentaires : Stocks

- Calcul des mois de stock :
  - Méthode qui consiste à calculer le nombre de mois restants avant que le stock soit écoulé
- Le nombre total de produits en stock est de *17803* bouteilles
- La valeur totale des stocks actuels est de *298540.07€*
- On observe une moyenne d'environ *3* mois de stock
- On dénombre *22* produits qui sont tombés en rupture de stock ce mois-ci
- Si on suit cette tendance, un produit tombera aussi en rupture de stock dans le mois qui vient

Analyses complémentaires : Stocks

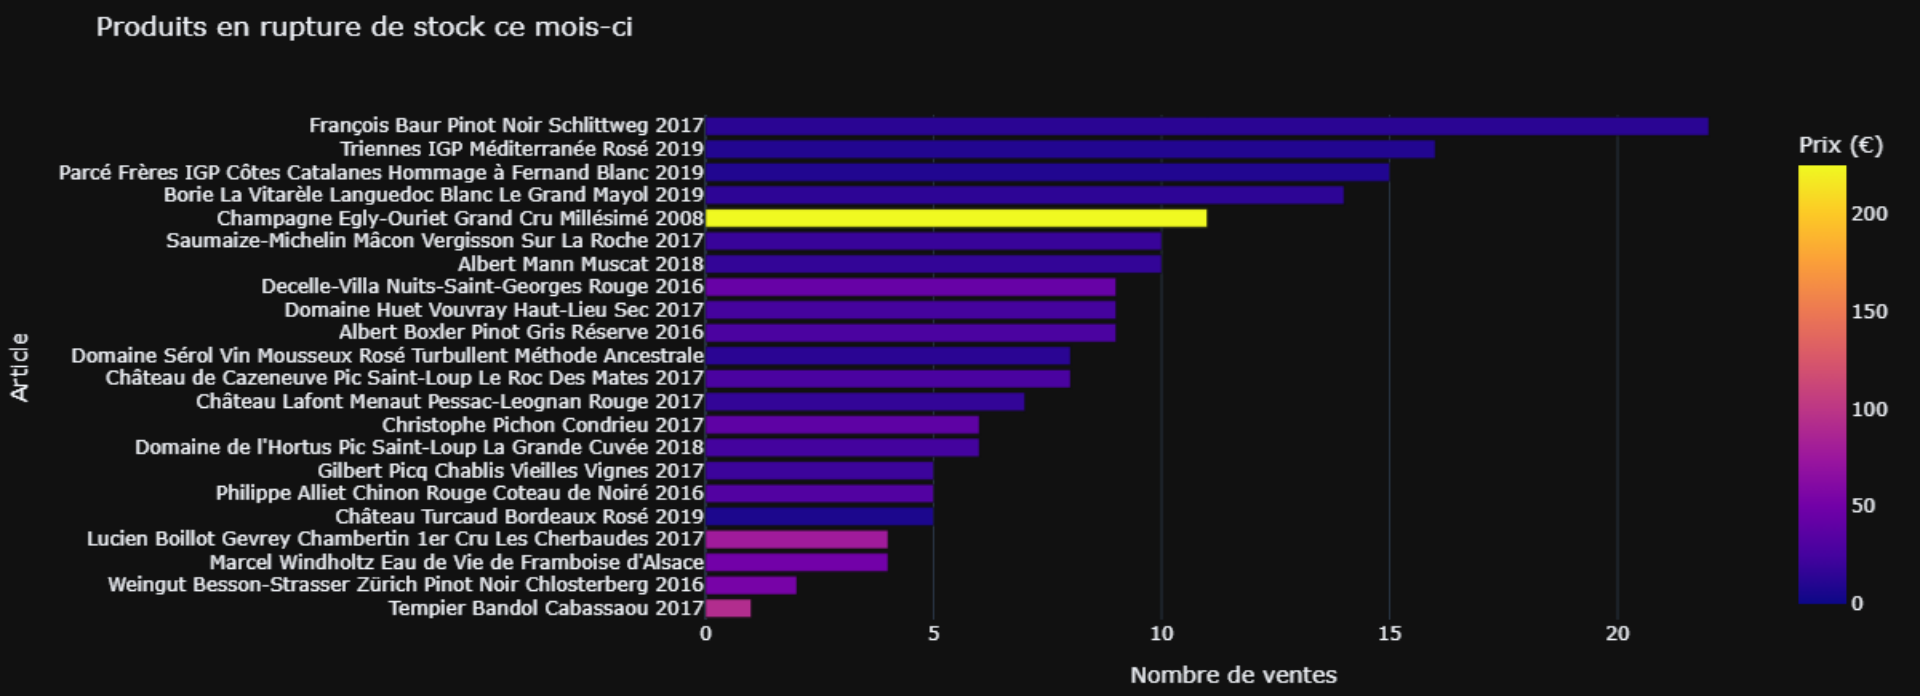

Analyses complémentaires : Stocks

Analyses complémentaires : Taux de marge

- En se basant sur un taux de TVA à 20%, on calcule les taux de marge pour chaque produit
- On trouve des taux de marge allant de 29.50% à 91.41%
- On a trouvé un produit ayant un taux de marge à -86.39% mais on a écarté ce cas car il s’agit surement d’un cas particulier

Analyses complémentaires : Taux de marge

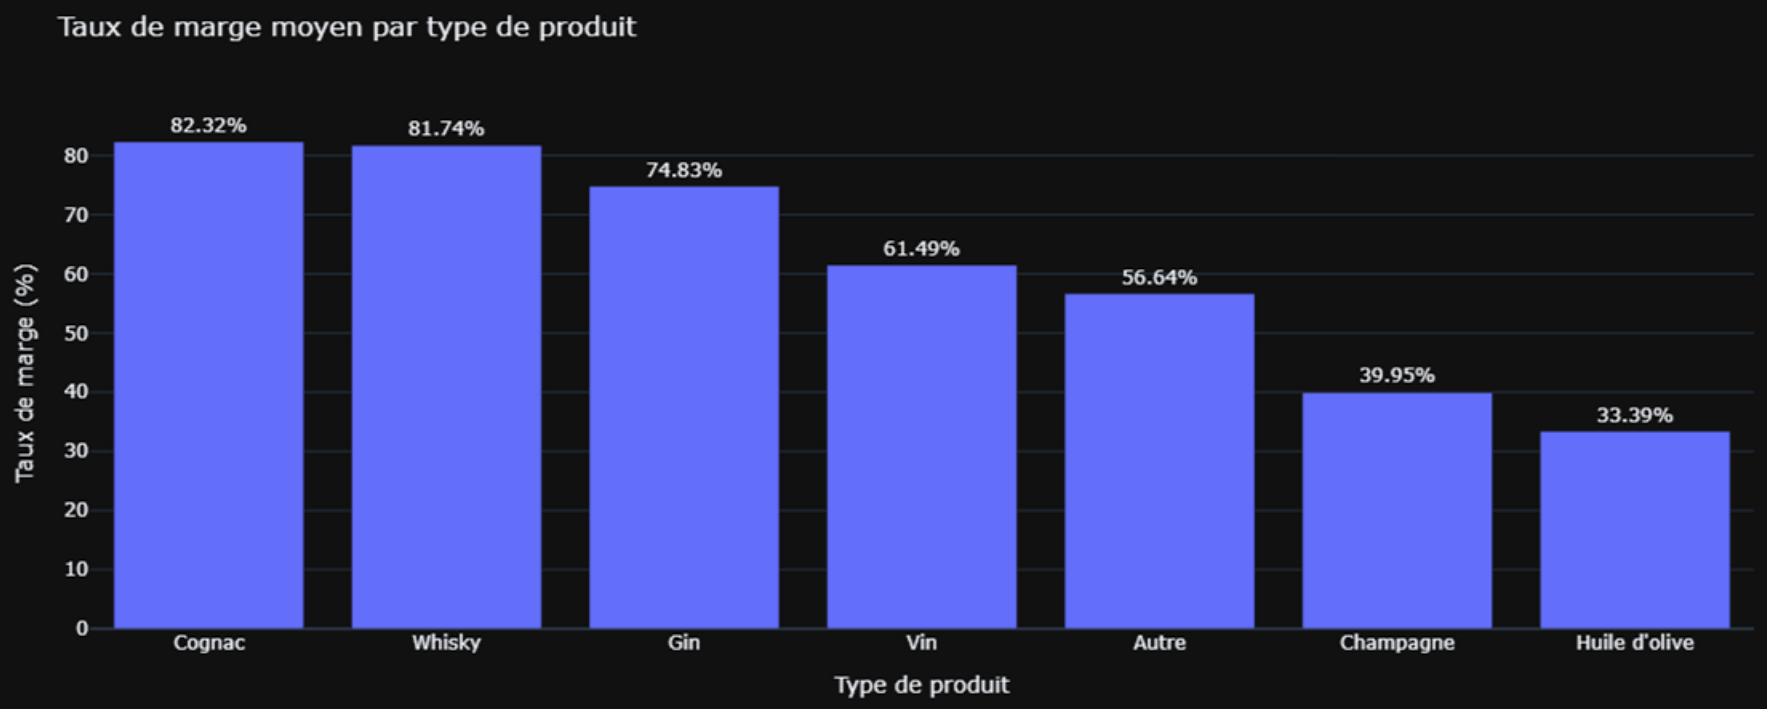

Analyses complémentaires : Corrélations

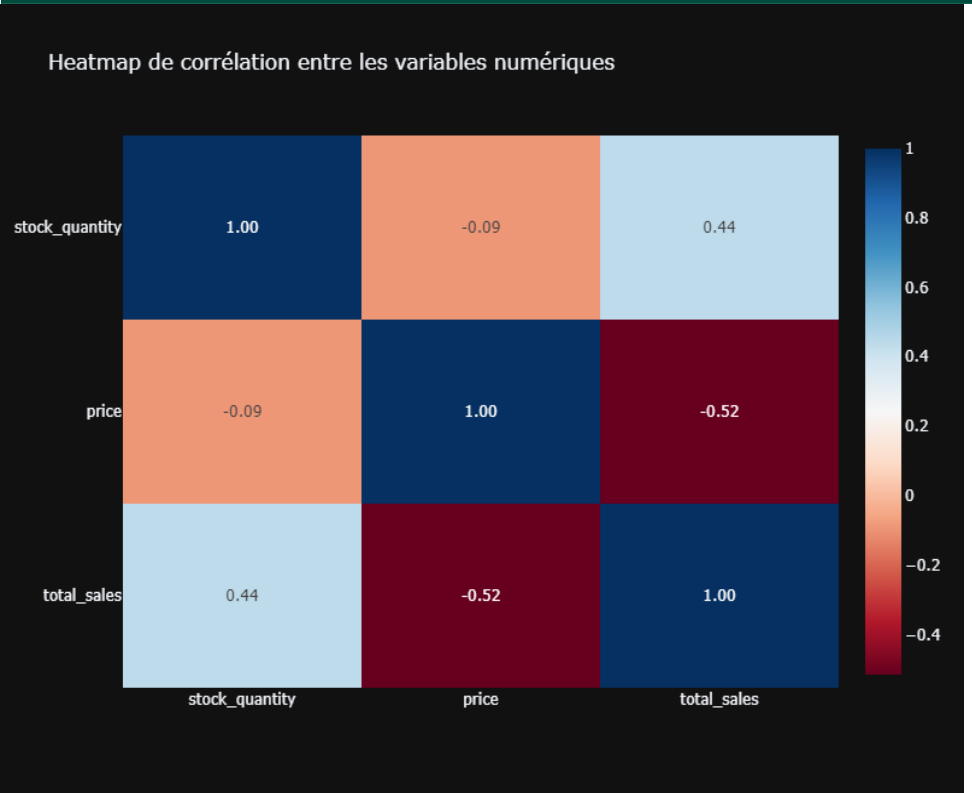

- Il y a une corrélation entre le stock et le nombre de vente, plus un produit est vendu, plus il y a de changement dans le stock
- Il y a une corrélation entre le prix et le nombre de vente, plus un produit est cher, moins il est vendu
- Il n'y a pas de corrélation entre le stock et le prix, le prix de vente n'influence pas le stock.

Actions pour la suite

- Le dataframe final a été exporté dans un fichier excel pour pouvoir le partager avec les équipes
- Restocker les bouteilles en rupture et rester vigilant quant à celles qui vont l'être prochainement
- Voir s'il est possible de légèrement modifier les prix de vente pour mener à une augmentation des ventes

Point sur les compétences apprises

- *Qu’est-ce qui s’est bien passé pour vous dans ce travail de nettoyage ?*
- *L’identification des lignes à supprimer/corriger*
- *Qu’est-ce que vous avez trouvé le plus difficile ?*
- *Le nettoyage des doublons d’identifiant sku dans le dataframe web*
- *Sur quelles tâches est-ce que vous pensez avoir besoin de plus d'entraînement ?*
- *L’analyse des résultats obtenus*