Détection de faux billets

TONY WENG

Contexte et Méthodologie

- Objectif : application qui permet de détecter la nature d'un billet (vrai/faux)

- Traitements et analyses en amont
- Différents algorithmes de Machine Learning
- Un modèle retenu pour l'application
- Création de l'application

Données & Traitement

Données initiales

- Fichier contenant 1500 billets (1000 vrais/500 faux)
- 7 colonnes

	diagonal	height_left	height_right	margin_low	margin_up	length
compte	1500	1500	1500	1463	1500	1500
moyenne	171.96	104.03	103.92	4.49	3.15	112.68
min	171.04	103.14	102.82	2.98	2.27	109.49
max	173.01	104.88	104.95	6.90	3.91	114.44

Données manquantes

- Corrélation entre margin_low et diagonal : -0.1115 (p-value: 0.0000)
- Corrélation entre margin_low et height_left : 0.3026 (p-value: 0.0000)
- Corrélation entre margin_low et height_right : 0.3911 (p-value: 0.0000)
- Corrélation entre margin_low et margin_up : 0.4316 (p-value: 0.0000)
- Corrélation entre margin_low et length : -0.6668 (p-value: 0.0000)
- Variables sélectionnées pour le modèle de régression linéaire : length

Régression linéaire : margin_low

Avant	Après
1463	1500
4.486	4.484
2.98	2.98
6.90	6.90

Prétraitement des données brutes

- Séparer les variables explicatives de la variable cible
  - X : diagonal, height_left, height_right, margin_low, margin_up, length
  - y : is_genuine
- Séparer l'échantillon en deux : un échantillon d'entrainement et un échantillon d'évaluation
- Normaliser les valeurs numériques (moyenne = 0, écart-type = 1)

Différents algorithmes

Régression logistique

- Résultats :
  - Accuracy score : 0.99
  - ROC/AUC score : 0.99

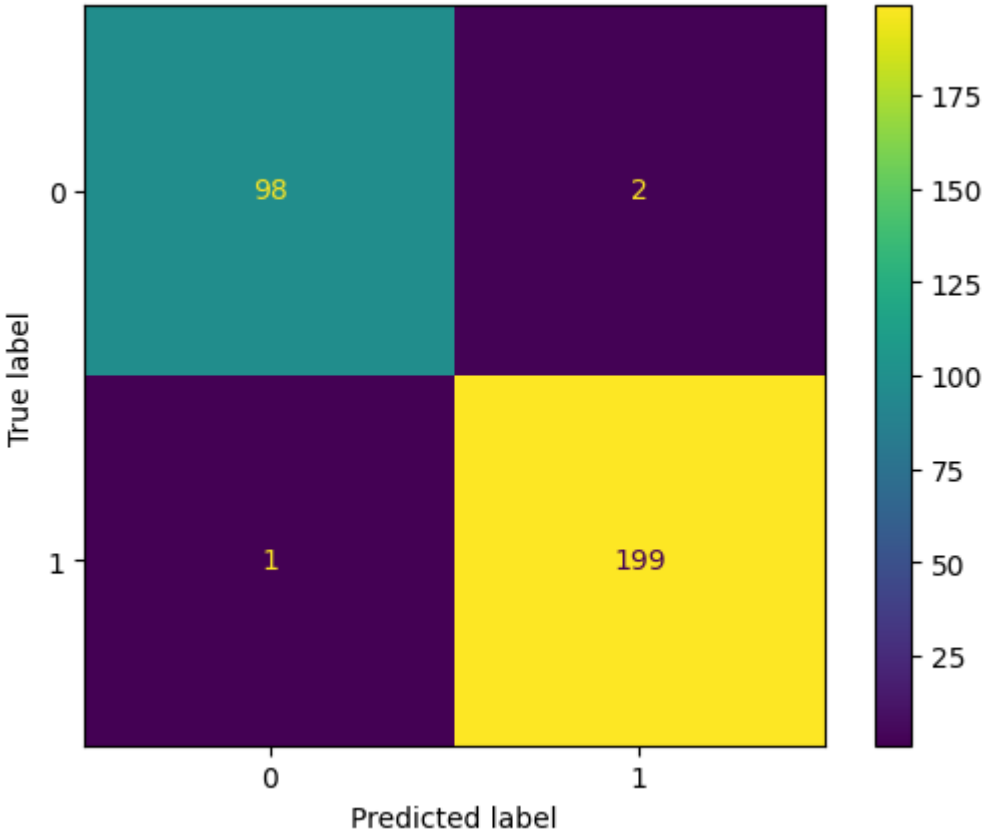

Méthode des k plus proches voisins (K Neighbors Classifier)

- Résultats :
  - Accuracy score : 0.98
  - ROC/AUC score : 0.98

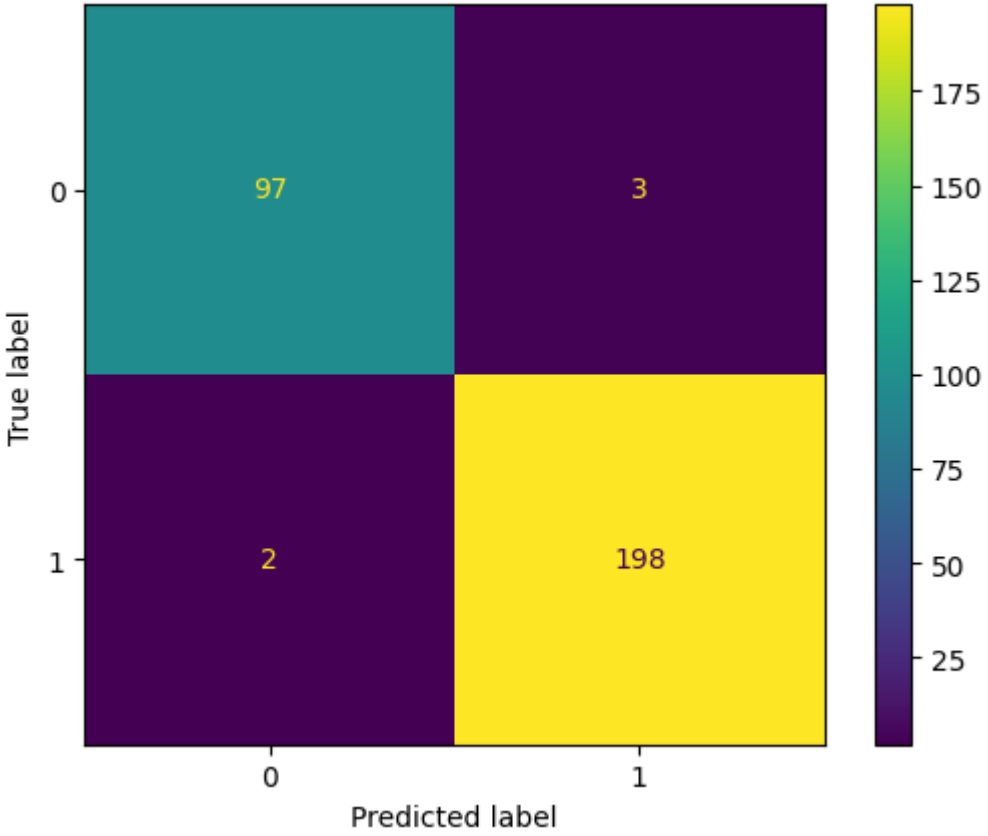

Forêt d'arbres décisionnels (Random Forest)

- Résultats :
  - Accuracy score : 0.99
  - ROC/AUC score : 0.99

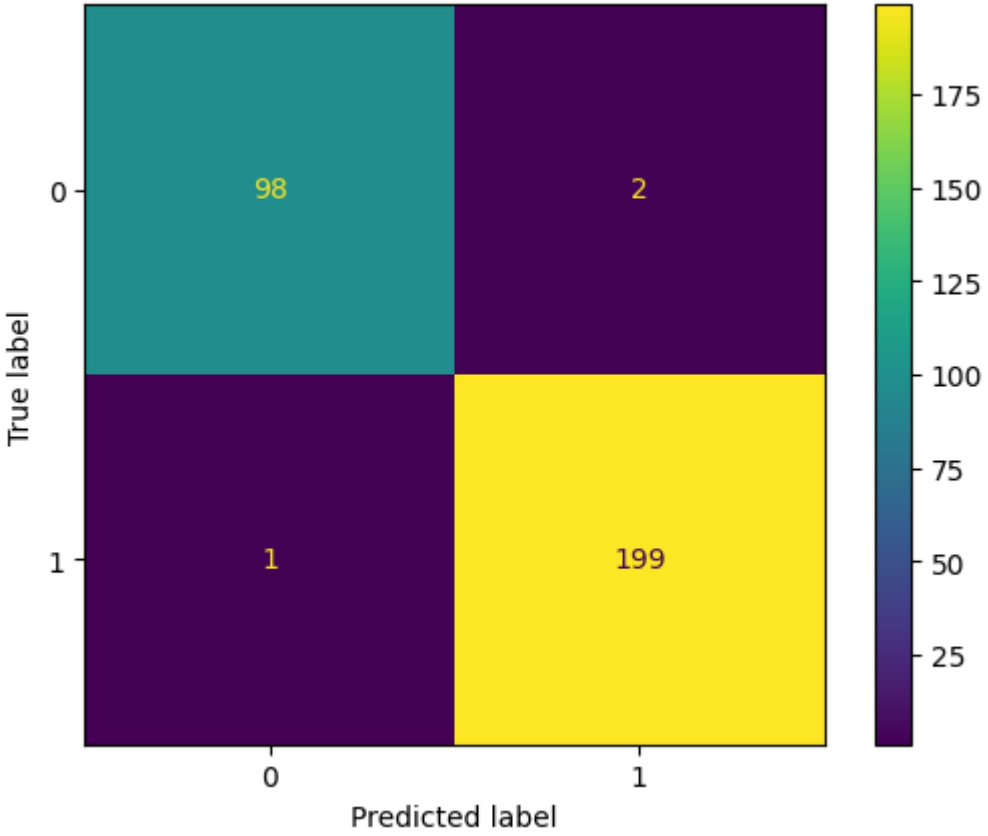

K means clustering

- Résultats :
  - Adjusted Rand Index : 0.9465770623742454
  - Accuracy score : 0.99
  - ROC/AUC score : 0.98

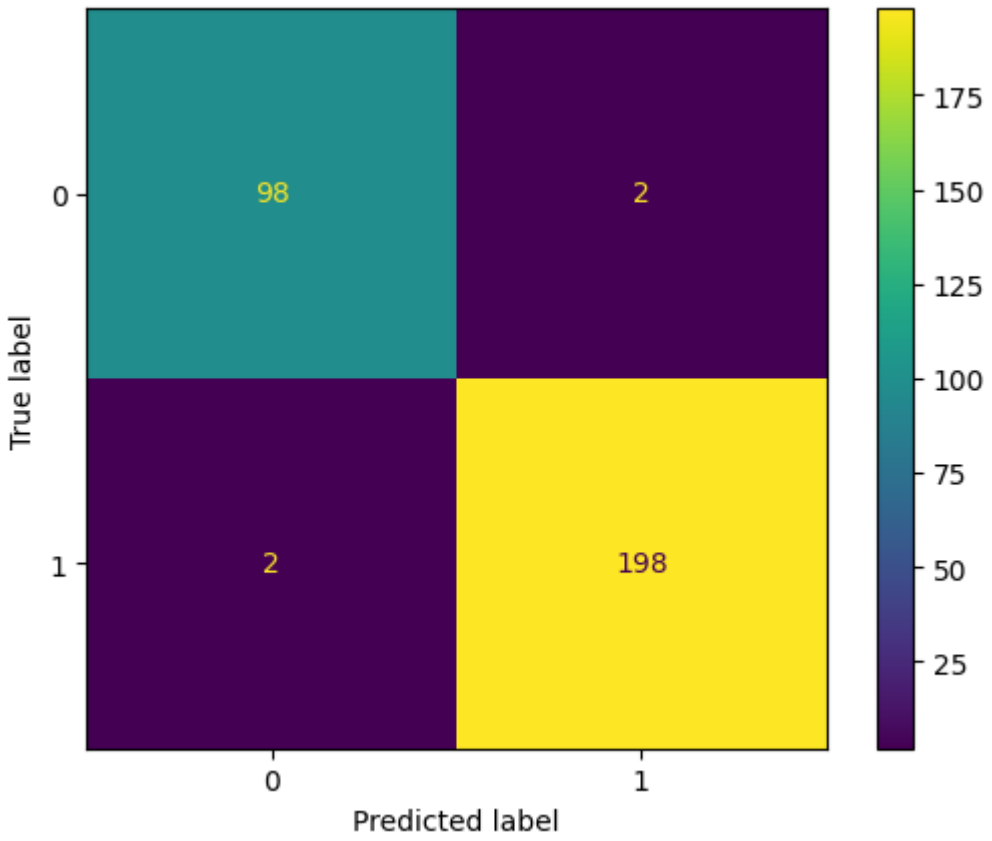

Modèle retenu

Régression Logistique/Random Forest

- Meilleure efficacité trouvée avec l'algorithme de Régression Logistique ou celui de Random Forest
- Le modèle retenu a été celui de Random Forest
- Dans un script à part, modèle entrainé

Application

prediction.py

- Utilisation : python3 prediction.py *'Nom du fichier CSV'*
- Affichera un tableau avec les caractéristiques des billets, la prédiction du modèle ainsi que la probabilité associée
- Compilera également le résultat dans un nouveau fichier CSV